

Expectativa de Vida Global

2016 – 2025

Construção de um pipeline completo de análise e modelagem preditiva a partir de dados da OMS sobre fatores de saúde e desenvolvimento humano.

DATASET	VARIÁVEL-ALVO	REGISTROS	NÍVEL
expectativa_vida_2016_2025.csv	Life Expectancy (anos)	~1.946 linhas 22 colunas	Avançado

CONTEXTO

01 Contexto de Negócio

A expectativa de vida ao nascer é um dos indicadores mais utilizados por organismos internacionais — OMS, Banco Mundial e PNUD — para medir o desenvolvimento humano de um país. Ela reflete a qualidade dos sistemas de saúde, a renda per capita, a educação e as condições sanitárias de uma população.

Neste business case, você assume o papel de cientista de dados em uma organização consultiva de saúde pública. A missão é construir um modelo preditivo capaz de estimar a expectativa de vida de um país em determinado ano, a partir de indicadores socioeconômicos e de saúde.

PERGUNTA CENTRAL

Quais fatores socioeconômicos e de saúde têm maior influência sobre a expectativa de vida de um país, e como podemos usá-los para prever anos futuros com precisão adequada?

PAÍSES	PERÍODO	FEATURES	TARGET
~193	10 anos	21	1 var.
entidades únicas	2016 a 2025	variáveis de entrada	Life Expectancy

DADOS

02 Dicionário de Dados

O dataset contém variáveis de três domínios: identificação, saúde e socioeconômico. Familiarize-se com cada coluna antes de iniciar a análise.

COLUNA	TIPO	DOMÍNIO	DESCRIÇÃO
Country	str	ID	Nome do país
Year	int	ID	Ano de referência
Status	cat	ID	Developing / Developed
Life expectancy	float	🎯 Target	Expectativa de vida ao nascer (anos)
Adult Mortality	int	Saúde	Óbitos adultos por 1.000 hab.
infant deaths	int	Saúde	Óbitos infantis por 1.000 nascidos vivos
Alcohol	float	Saúde	Consumo de álcool per capita (litros/ano)
percentage expenditure	float	Socioec.	Gasto em saúde como % do PIB per capita
Hepatitis B / Polio / DTP	float	Saúde	Cobertura vacinal (%)

Measles	int	Saúde	Casos de sarampo reportados
BMI	float	Saúde	Índice de Massa Corporal médio da população
HIV/AIDS	float	Saúde	Óbitos por HIV/AIDS por 1.000 nascidos vivos
GDP	float	Socioec.	PIB per capita (USD)
Population	float	Socioec.	Tamanho da população
thinness 1-19 / 5-9 years	float	Saúde	Prevalência de magreza (%)
Income composition	float	Socioec.	Índice de composição de renda (0–1)
Schooling	float	Socioec.	Média de anos de escolaridade

ETAPA 1

03 Análise Exploratória de Dados (EDA)

O objetivo da EDA é compreender a estrutura, distribuição e qualidade dos dados antes de qualquer transformação ou modelagem. Esta etapa direciona todas as decisões posteriores.

3.1 — Inspeção Inicial

Carregue o dataset e realize uma primeira análise estrutural: `shape`, `dtypes`, `head()`, `describe()` e contagem de missings por coluna.

```
python · etapa_01_eda.py

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv("expectativa_vida_2016_2025.csv")

# Inspeção estrutural
print(df.shape)
print(df.dtypes)
df.describe(include="all").T

# Valores ausentes por coluna
missing_pct = (df.isnull().sum() / len(df)) * 100
print(missing_pct[missing_pct > 0].sort_values(ascending=False))

# Distribuição da variável-alvo
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
df["Life expectancy "].hist(ax=axes[0], bins=40, color="#1A5CFF")
sns.boxplot(x="Status", y="Life expectancy ", data=df, ax=axes[1])
plt.tight_layout(); plt.show()
```

3.2 — Análise Temporal e Geográfica

```
python
```

```
# Evolução média global por ano
trend = df.groupby("Year")["Life expectancy"].mean()
trend.plot(marker="o", figsize=(10,4), color="#1A5CFF")
plt.title("Expectativa de Vida Média Global por Ano"); plt.show()

# Top 10 países com maior expectativa de vida
top10 = df.groupby("Country")["Life expectancy"].mean().nlargest(10)
print(top10)
```

3.3 — Perguntas Orientadoras

- Q1 — Qual a distribuição da variável-alvo? É normal, bimodal ou assimétrica?
- Q2 — Quanto de dados ausentes existem? Quais colunas têm >10% de missings?
- Q3 — Países em desenvolvimento vs. desenvolvidos diferem significativamente? (Mann-Whitney)
- Q4 — Quais variáveis têm alta skewness? Como tratar GDP, Population, Measles?

ATENÇÃO — QUALIDADE DOS DADOS

O CSV apresenta problemas reais: valores como "67,55" com vírgula decimal, espaços extras em nomes de países, valores negativos implausíveis (Adult Mortality = -5) e categorias inconsistentes em Status (ex: "DEVELOPING"). Identifique na EDA e trate no Data Munging.

ETAPA 2

04 Data Munging

O dataset bruto contém múltiplos problemas de qualidade que devem ser corrigidos sistematicamente. Este é um cenário próximo da realidade de produção.

```
python · etapa_02_munging.py
```

```
# 1. Normalizar nomes de colunas
df.columns = (df.columns.str.strip().str.lower()
              .str.replace(" ", "_")
              .str.replace(r"^[a-z0-9_]", "", regex=True))

# 2. Limpar coluna Country
df["country"] = df["country"].str.strip()

# 3. Tratar vírgulas em campos numéricos
# Ex: "67,55" -> 67.55 | "43,519,481" -> 43519481
def fix_numeric(series):
    return (series.astype(str)
            .str.replace(r"(?<=\d),(?=\d{3})(?:[,\\s]|$)", "", regex=True))
```

```
.str.replace(",", ".")
.replace("nan", np.nan)
.pipe(pd.to_numeric, errors="coerce"))

# 4. Normalizar Status (evitar "DEVELOPING", " Developing ")
df["status"] = df["status"].str.strip().str.title()

# 5. Outliers implausíveis -> NaN
df.loc[df["adult_mortality"] < 0, "adult_mortality"] = np.nan

# 6. Imputação por grupo: mediana do país, fallback Status, fallback global
def impute_by_group(df, col, groups):
    df[col] = df.groupby(groups)[col].transform(
        lambda x: x.fillna(x.median()))
    return df

for col in num_cols:
    df = impute_by_group(df, col, ["country"])
    df = impute_by_group(df, col, ["status"])
    df[col].fillna(df[col].median(), inplace=True)

print(f"Missings restantes: {df.isnull().sum().sum()}")
```

ENTREGÁVEL

Ao final desta etapa: DataFrame sem valores ausentes, Status com apenas 2 categorias, todos os campos numéricos com tipo correto. Salve como df_clean.csv.

ETAPA 3**05 Engenharia de Recursos**

A engenharia de recursos transforma e combina variáveis brutas para capturar relações não-lineares, reduzir skewness e criar indicadores com maior poder preditivo.

```
python · etapa_03_features.py

# 1. Transformações logarítmicas (variáveis com alta skewness)
for col in ["gdp", "population", "measles", "percentage_expenditure"]:
    df_feat[f"log_{col}"] = np.log1p(df_feat[col])

# 2. Cobertura vacinal média
df_feat["vaccine_coverage_avg"] = df_feat[
    ["hepatitis_b", "polio", "diphtheria"]].mean(axis=1)

# 3. Pressão de doenças transmissíveis
df_feat["disease_burden"] = df_feat["hiv_aids"] + df_feat["measles"]

# 4. Magreza consolidada (alta correlação entre as duas colunas)
df_feat["thinness_avg"] = df_feat[
    ["thinness_119_years", "thinness_59_years"]].mean(axis=1)
```

```
# 5. Encoding categórico
df_feat["status_enc"] = (df_feat["status"] == "Developed").astype(int)

# 6. Feature temporal normalizada (0 a 1)
df_feat["year_norm"] = (df_feat["year"] - 2016) / 9

# 7. Escalonamento para modelos lineares
scaler = StandardScaler()
df_feat[feature_cols] = scaler.fit_transform(df_feat[feature_cols])
```

FEATURE NOVA	ORIGEM	MOTIVAÇÃO
log_gdp	GDP	Reduz skewness; relação com saúde é log-linear
vaccine_coverage_avg	HepB + Polio + DTP	Índice sintético de imunização
disease_burden	HIV + Measles	Pressão agregada de doenças infecciosas
thinness_avg	thinness cols	Evita multicolinearidade sem perder informação
mortality_le_ratio	Adult Mort. / LE	Mortalidade relativa à longevidade atual
year_norm	Year	Tendência temporal normalizada (0 a 1)

ETAPA 4

06 Correlação e Multicolinearidade

Antes da modelagem, verifique se variáveis preditoras são fortemente correlacionadas entre si. A multicolinearidade pode inflar erros padrão e tornar coeficientes instáveis em modelos lineares.

```
python · etapa_04_correlacao.py

from statsmodels.stats.outliers_influence import variance_inflation_factor
from statsmodels.tools.tools import add_constant

# Mapa de calor de correlação
corr = df_feat[feature_cols + ["life_expectancy"]].corr()
mask = np.triu(np.ones_like(corr, dtype=bool))
sns.heatmap(corr, mask=mask, cmap="RdBu_r", center=0,
            annot=True, fmt=".2f", linewidths=.5)
plt.title("Matriz de Correlação"); plt.show()

# Top 10 correlações com o target
target_corr = corr["life_expectancy"].drop("life_expectancy").abs()
print(target_corr.sort_values(ascending=False).head(10))
```

```
# Fator de Inflação de Variância (VIF)
X_vif = add_constant(df_feat[feature_cols].dropna())
vif_data = pd.DataFrame({
    "feature": X_vif.columns,
    "VIF": [variance_inflation_factor(X_vif.values, i)
            for i in range(X_vif.shape[1])]
}).sort_values("VIF", ascending=False)
print(vif_data)
# Regra: VIF > 10 -> alta multicolinearidade -> remover ou consolidar
```

MULTICOLINEARIDADE ESPERADA

Alta correlação esperada entre: thinness_1-19 e thinness_5-9 ($r \sim 0.98$), infant_deaths e under-five_deaths ($r \sim 0.99$), e entre as coberturas vacinais. Use VIF > 10 como critério de corte.

ETAPA 5

07 Modelagem Estatística (OLS)

A modelagem com OLS (Mínimos Quadrados Ordinários) fornece interpretabilidade: coeficientes com significância, intervalos de confiança e diagnósticos de resíduo.

```
python · etapa_05_regressao_ols.py

import statsmodels.api as sm

selected = [
    "adult_mortality", "log_gdp", "schooling",
    "income_composition_of_resources", "vaccine_coverage_avg",
    "hiv_aids", "thinness_avg", "status_enc", "year_norm",
    "total_expenditure", "bmi"
]

X_const = sm.add_constant(df_feat[selected])
model = sm.OLS(y, X_const).fit()
print(model.summary())

# Diagnóstico de resíduos (4 plots)
fig, axes = plt.subplots(2, 2, figsize=(12, 8))
# Resíduo vs Fitted
axes[0,0].scatter(model.fittedvalues, model.resid, alpha=0.4, s=10)
axes[0,0].axhline(0, color="red", linestyle="--")
axes[0,0].set_title("Resíduos vs Valores Ajustados")
# Q-Q Plot
sm.qqplot(model.resid, line="s", ax=axes[0,1])
axes[0,1].set_title("Q-Q Plot dos Resíduos")
# Histograma de resíduos
axes[1,0].hist(model.resid, bins=40)
axes[1,0].set_title("Distribuição dos Resíduos")
plt.tight_layout(); plt.show()
```

INDICADOR	O QUE SIGNIFICA	BENCHMARK
R ²	Proporção da variância explicada pelo modelo	> 0.85
Adj. R ²	R ² penalizado pelo número de variáveis	> 0.83
p-value (F)	Teste global de significância do modelo	< 0.05
p-value (coef)	Significância individual de cada variável	< 0.05
JB test	Teste de normalidade dos resíduos	p > 0.05 = ok
Durbin-Watson	Autocorrelação dos resíduos	~ 2.0
Cond. No.	Número de condição — multicolinearidade	< 30

ETAPA 6

08 Modelagem Preditiva

Com os dados preparados, treine e compare múltiplos algoritmos de regressão. O objetivo é encontrar o melhor trade-off entre desempenho e interpretabilidade.

```
python · etapa_06_preditiva.py
```

```
from sklearn.model_selection import train_test_split, cross_val_score, KFold
from sklearn.linear_model import LinearRegression, Ridge, Lasso
from sklearn.ensemble import RandomForestRegressor, GradientBoostingRegressor
from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
import xgboost as xgb
```

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42)
```

```
models = {
    "Linear Regression": LinearRegression(),
    "Ridge (alpha=1)": Ridge(alpha=1.0),
    "Lasso (alpha=0.1)": Lasso(alpha=0.1),
    "Random Forest": RandomForestRegressor(n_estimators=200,
random_state=42),
    "Gradient Boosting": GradientBoostingRegressor(n_estimators=200,
random_state=42),
    "XGBoost": xgb.XGBRegressor(n_estimators=200,
random_state=42),
}
```

```
kf = KFold(n_splits=5, shuffle=True, random_state=42)
for name, model in models.items():
    cv_r2 = cross_val_score(model, X_train, y_train, cv=kf, scoring="r2")
    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)
    # Registrar: cv_r2_mean, test_rmse, test_mae
```


8.1 — Importância de Variáveis

```
python

importances = pd.Series(
    best_model.feature_importances_, index=selected
).sort_values(ascending=False)

importances.plot(kind="barh", figsize=(10, 6), color="#1A5CFF")
plt.title("Importância de Variáveis - XGBoost")
plt.gca().invert_yaxis(); plt.show()
```

ETAPA 7

09 Avaliação do Modelo

A avaliação vai além das métricas numéricas. Analise onde e como o modelo erra, e se generaliza para diferentes regiões e faixas de desenvolvimento.

```
python · etapa_07_avaliacao.py

# 1. Gráfico Real vs. Previsto
fig, ax = plt.subplots(figsize=(8, 6))
ax.scatter(y_test, y_pred, alpha=0.5, s=15, color="#1A5CFF")
ax.plot([y_test.min(), y_test.max()],
        [y_test.min(), y_test.max()], "r--", lw=1.5)
ax.set_xlabel("Real"); ax.set_ylabel("Previsto")
ax.set_title("Real vs. Previsto - Expectativa de Vida")
plt.show()

# 2. Análise de erro por Status
test_df["error"] = (test_df["y_pred"] - test_df["y_real"]).abs()
print(test_df.groupby("status")["error"].describe())

# 3. Curva de Aprendizado
from sklearn.model_selection import learning_curve
train_sizes, train_scores, val_scores = learning_curve(
    best_model, X_train, y_train, cv=5, scoring="r2",
    train_sizes=np.linspace(0.1, 1.0, 10))
plt.plot(train_sizes, train_scores.mean(axis=1), label="Treino")
plt.plot(train_sizes, val_scores.mean(axis=1), label="Validacao")
plt.title("Curva de Aprendizado"); plt.legend(); plt.show()
```

MÉTRICA	DEFINIÇÃO	INTERPRETAÇÃO
RMSE	Raiz do Erro Quadrático Médio	Erro em anos; penaliza desvios grandes
MAE	Erro Absoluto Médio	Erro médio em anos; robusto a outliers

R ²	Coefficiente de Determinação	% da variância explicada
MAPE	Erro Percentual Absoluto Médio	Erro relativo %; útil para comunicação
CV R ²	R ² médio em k-folds	Estabilidade e capacidade de generalização

ETAPA 8

10 Previsão com Novos Dados

O modelo treinado deve receber dados de novos países (ou anos hipotéticos) e retornar uma estimativa com intervalo de confiança para apoiar decisões de política pública.

```
python · etapa_08_previsao.py

# Cenário hipotético: país de desenvolvimento médio, 2027
novo_pais = pd.DataFrame([
    "adult_mortality": 145,
    "log_gdp": np.log1p(4200),
    "schooling": 11.5,
    "income_composition_of_resources": 0.62,
    "vaccine_coverage_avg": 82.0,
    "hiv_aids": 0.4,
    "thinness_avg": 6.5,
    "status_enc": 0, # Developing
    "year_norm": (2027-2016)/9,
    "total_expenditure": 6.1,
    "bmi": 24.5,
])

pred = best_model.predict(scaler.transform(novo_pais[selected]))
print(f"Expectativa de vida prevista: {pred[0]:.2f} anos")

# Intervalo de confiança via Bootstrap (500 amostras)
bootstrap_preds = []
for _ in range(500):
    X_bs, y_bs = resample(X_train, y_train)
    m = RandomForestRegressor(n_estimators=50, random_state=42)
    m.fit(X_bs, y_bs)
    bootstrap_preds.append(m.predict(novo_pais_scaled)[0])

ci_low = np.percentile(bootstrap_preds, 2.5)
ci_high = np.percentile(bootstrap_preds, 97.5)
print(f"IC 95%: [{ci_low:.2f}, {ci_high:.2f}] anos")
```

DESAFIO EXTRA

Simule dois cenários políticos: (A) aumento de 20% nos gastos com saúde; (B) redução de HIV/AIDS para 0.1. Compare as previsões e construa um argumento de recomendação baseado em dados para um decisor público.